인문학을 위한 한국어처리

경희대학교

박정열

Department of Linguistics University at Buffalo jungyeul@buffalo.edu

2019년 7월4일

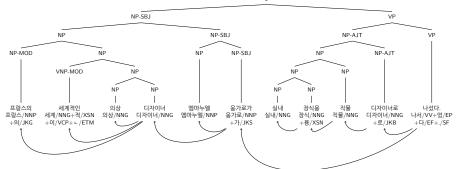
Overview

① 형태소 분석 및 품사 태깅

② 구구조 분석

③ 의존구조 분석





- 형태소 분석 및 품사 태깅: Park J, Tyers F. A New Annotation Scheme for the Sejong Part-of-speech Tagged Corpus. In: Proceedings of the 13th Linguistic Annotation Workshop (The LAW XIII).; 2019 (August 1, 2019).
- ② 구구조 및 의존구조 분석: Park J, Hong J-P, Cha J-W. Korean Language Resources for Everyone. In: Proceedings of the 30th Pacific Asia Conference on Language, Information and Computation: Oral Papers (PACLIC 30). Seoul, Korea: Pacific Asia Conference on Language, Information and Computation; 2016:49-58. http://aclweb.org/anthology/Y/Y16/Y16-2002.pdf.
- ③ 실습파일: https://github.com/jungyeul/july2019-kyunghee
- ⑤ 강의파일: https://www.overleaf.com/read/ghwqrpktvctr

형태소 분석 및 품사 태깅

형태소 분석 및 품사 태깅의 입력과 출력

입력:

프랑스의 세계적인 의상 디자이너 엠마누엘 웅가로가 실내 장식용 직물 디자이너로 나섰다.

출력:

프랑스의 BOS 프랑스/NNP+의/JKG

세계적인 세계/NNG+적/XSN+이/VCP+ L/ETM

의상 의상/NNG

디자이너 디자이너/NNG 엠마누엘 엠마누엘/NNP

응가로가 응가로/NNP+가/JKS

실내 실내/NNG

장식용 장식/NNG+용/XSN

직물 직물/NNG

디자이너로 디자이너/NNG+로/JKB

나섰다. EOS 나서/VV+었/EP+다/EF+./SF

```
<source>
<date>
                     1993/06/08
                                1993/SN + //SP + 06/SN + //SP + 08/SN
RTAA0001-00000001
</date>
<page>
BTAA0001-00000002
                      19
                             19/SN
</page>
</source>
<head>
                                   엠마누엘/NNP
                      엠마누엘
RT440001-00000003
                      웅가로 웅가로/NNP
BTAA0001-00000004
                             //SP
BTAA0001-00000005
                      의상서 의상/NNG + 서/JKB
BTAA0001-00000006
                      실내
                            실내/NNG
RT440001-00000007
                      장식품으로...
BTAA0001-00000008
                                     장식품/NNG + 으로/JKB + .../SE
BTAA0001-00000009
                      디자인 디자인/NNG
                     세계
                            세계/NNG
BTAA0001-00000010
BTAA0001-00000011
                      넓혀
                            넓히/VV + 어/EC
</head>
>
                      프랑스의
                                   프랑스/NNP + 의/JKG
BTAA0001-00000012
BTAA0001-00000013
                     세계적인
                                   세계/NNG + 적/XSN + 이/VCP + L/ETM
                      의상
                            의상/NNG
RT440001-00000014
BTAA0001-00000015
                      디자이너
                                   디자이너/NNG
                      엠마누엘
                                   엠마누엘/NNP
BTAA0001-00000016
                                   웅가로/NNP + 가/JKS
BTAA0001-00000017
                      웅가로가
BTAA0001-00000018
                      실내
                            실내/NNG
                      장식용 장식/NNG + 용/XSN
BTAA0001-00000019
BTAA0001-00000020
                      직물
                             직물/NNG
                                   디자이너/NNG + 로/JKB
BTAA0001-00000021
                      디자이너로
BTAA0001-00000022
                     나섰다. 나서/VV + 었/EP + 다/EF + ./SF
>
```



[0, 7] 나+서+ 었+다, 나서+ 었+다, 나+섰 다, [0, 6]	[1, 7]	1		나섰더	ᆉ⇒ㄴㅏㅅ	ተ ሥ ⊏
[0, 5]	[1, 6]	[2,7] 섰다, 서+았+다, 서+었+다				
[0,4] 나서, 나+서	[1, 5]	[2, 6]	[3, 7]			
[0, 3] 낫	[1, 4]	[2, 5]	[3, 6]	[4,7] 았+다, 었+다		
[0, 2] 나	[1, 3]	[2, 4] 서	[3, 5]	[4, 6]	[5, 7] 다	
[0, 1] ∟	[1, 2]	[2, 3]	[3, 4]	[4, 5] 았,었	[5, 6]	[6, 7]
L	ŀ	^	+	ж	_	ŀ

0.71 U+A+ St+G, UA+ St+G, U+St]					
[0, 6] [0, 5]	[1, 7]	19 71 MD	_	나섰	다⇒ㄴㅏ↗	1 * = 1
[4,4]	(1, 1)	서+함+다. 서+었+다				
[0,4] 나서. 나+서	[1, 5]	[2, 6]	[3, 7]			
[0, 3] ···	[1, 4]	[2, 5]	[3, 6]	[4, 기 있+나. 업+다		
0,2 나	1, 3	[2, 4] M	[3, 5]	[4, 6]	[5.기다	
Fact of	1,2	, [2,3]	1 [3, 4]	4.5 92.9	[5,6] C	6,7

[2,7]
$$= [2,3] + [3,7] = \emptyset + \emptyset$$

 $= [2,4] + [4,7] = \mathcal{H} + (었|었+다)$
 $= [2,5] + [5,7] = \emptyset + \Gamma$
 $= [2,6] + [6,7] = \emptyset + \emptyset$
 $= [2,7] = \text{셨다 (modified cky)}$

형태소 분석 및 품사 태깅 자원

- UDPipe (Straka and Straková, 2017)¹를 사용한 한국어 형태소 분석 및 품사 태깅 (Park and Tyers, 2019)²
- ExpressoK³ (Park et al., 2016)⁴

¹http://ufal.mff.cuni.cz/udpipe

²https://github.com/jungyeul/sjmorph

³http://air.changwon.ac.kr/~airdemo/kg_tagger/

⁴http://doi.org/10.5281/zenodo.884606

형태소 분석 및 품사 태깅 실습

- udpipe --input=horizontal --tokenizer=presegmented
 --tag sjmorph.model input.txt > udpipe-output.txt
- ② java UDPipe2Espresso udpipe-output.txt >
 sejong-output.txt

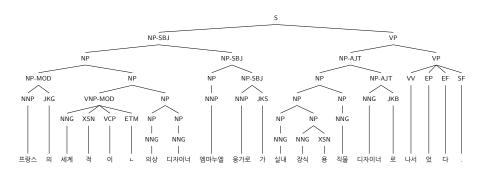
```
# newdoc id = input.txt
# newpar
# sent_id = 1
# text = 프랑스의 세계적인 의상 디자이너 엠마누엘 웅가로가 실내 장식용 직물 디자이너로 나섰다.
1-2 프랑스의 _
1 프랑스 프랑스 PROPN NNP _ _ _ _ _
2 의 의 ADP JKG _ _ _ _ _
3-6 세계적인 _ _ _ _ _
3 세계 세계 NOUN NNG _ _ _ _ _
4 적 적 PRT XSN _ _ _ _ _
5 Ol Ol VERB VCP _ _ _ _
6 ∟ ∟ PRT ETM
7 의상 의상 NOUN NNG _ _ _ _ _
8 디자이너 디자이너 NOUN NNG _ _ _ _ _
9 엠마누엘 엠마누엘 PROPN NNP _ _ _ _ _
10-11 웅가로가 _ _ _ _ _ _
10 웅가로 웅가로 PROPN NNP _ _ _ _ _
11 가 가 ADP JKS _ _ _ _
12 실내 실내 NOUN NNG _ _ _ _ _
13-14 장식용 _ _ _ _ _
13 장식 장식 NOUN NNG _ _ _ _
14 용 용 PRT XSN _ _ _ _ _
15 직물 직물 NOUN NNG _ _ _ _
16-17 디자이너로 _ _ _ _ _
16 디자이너 디자이너 NOUN NNG
17 로 로 ADP JKB _ _ _ _
18-20 나섰다 _ _ _ _ SpaceAfter=No
18 나서 나서 VERB VV _ _ _ _ _
20 다 다 PRT EF _ _ _ _
```

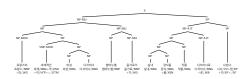
21 . . PUNCT SF _ _ _ SpacesAfter=\n

구구조 분석

구구조 분석 입력과 출력

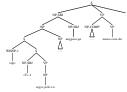
```
입력:
프랑스 의 세계 적 이 ㄴ 의상 디자이너 엠마누엘 웃가로 가 실내 장식 용 직물 디자이너 로 나
서 었다.
출력:
(S (NP-SBJ (NP (NP-MOD (NNP 프랑스) (JKG 의)
           (NP (VNP-MOD (NNG 세계) (XSN 적) (VCP 이) (ETM ∟))
                (NP (NP (NNG 의상))
                     (NP (NNG 디자이너)))))
                         (NP-SBJ (NP (NNP 엠마누엘))
                                   (NP-SBJ (NNP 웅가로) (JKS 가))))
   (VP (NP-AJT (NP (NP (NP (NNG 실내))
                         (NP (NNG 장식) (XSN 용)))
                     (NP (NNG 직물)))
                (NP-AJT (NNG 디자이너) (JKB 로)))
       (VP (VV 나서) (EP 었) (EF 다) (SF .))))
```



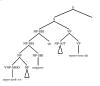




(a) Sejong treebank



(b) Penn Korean treebank



(c) Korean tree-adjoining grammar

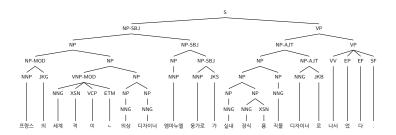


(d) KAIST treebank



(e) Phrase structure parsing for Korean

figures from Park (2018)



- CFG 규칙추출: V → (V ∪ Σ)*
- CFG를 CNF로 변경후 CKY 알고리즘 적용: $A \rightarrow BC$ or $A \rightarrow c$ where $A, B, C \in V$ and $c \in \Sigma$

CFG	CNF
NP → NP-MOD NP	NP → NP-MOD NP
$NP-MOD \rightarrow NNP JKG$	$NP-MOD \rightarrow NNP JKG$
$NP \rightarrow VNP-MOD NP$	$NP \rightarrow VNP-MOD NP$
${\tt VNP-MOD} o {\tt NNG} {\tt XSN} {\tt VCP} {\tt ETM}$	$VNP-MOD \rightarrow NNG X1$
	X1 \rightarrow XSN X2
	$X2 \rightarrow VCP ETM$

구구조 분석 자원

- Berkeley (Petrov et al., 2006)파서⁵를 사용한 한국어 구구조 분석 (Park, 2017a)⁶
 - 한국어 구구조 분석 연구 (Choi et al., 2012; Park et al., 2016)
 - 한국어 구구조 분석 오류 분석 (Park and Kim, 2019)

⁵https://github.com/slavpetrov/berkeleyparser

⁶http://doi.org/10.5281/zenodo.891267

구구조 분석 실습

- 토큰만 사용한 구구조 분석
 - java UDPipe2tok udpipe-output.txt > udpipe-tokenized.txt
 - java -jar BerkeleyParser-1.7.jar -gr
 berkeley.sjtree.model < udpipe-tokenized.txt >
 berkeley-token-output.txt
- ② 토큰 및 품사를 사용한 구구조 분석
 - java MakeBerkeleyTestWithPOSIn sejong-output.txt >
 berkeley-pos-input.txt
 - java -jar BerkeleyParser-1.7.jar -useGoldPOS -gr berkeley.sjtree.model < berkeley-pos-input.txt > berkeley-pos-output.txt

의존구조 분석

의존구조 분석 입력과 출력

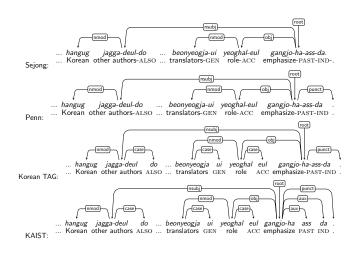
입력:

1	프랑스의	프랑스	NNP	NNP+JKG	JKG
2	세계적인	세계적이	NNG+XSN+VCP	NNG+XSN+VCP+ETM	ETM
3	의상	의상	NNG	NNG	_
4	디자이너	디자이너	NNG	NNG	_
5	엠마누엘	엠마누엘	NNP	NNP	_
6	웅가로가	웅가로	NNG	NNG+JKS	JKS
7	실내	실내	NNG NNG	-	
8	장식용	장식용	NNG	NNG	_
9	직물	직물	NNG	NNG	_
10	디자이너로	디자이너	NNG	NNG+JKB JKB	
11	나섰다.	나서	VV	VV+EP+EF+SF	EP EF SF

출력:

_	•								
1	프랑스의	프랑스	NNP	NNP+JKG	JKG	4	NP-MOD	_	_
2	세계적인	세계적이	NNG+XSN+VCP	NNG+XSN+VCP+ETM	ETM	4	VNP-MOD	_	_
3	의상	의상	NNG	NNG	_	4	NP	_	_
4	디자이너	디자이너	NNG	NNG	_	6	NP	_	_
5	엠마누엘	엠마누엘	NNP	NNP	_	6	NP	_	_
6	웅가로가	웅가로	NNG	NNG+JKS	JKS	11	NP-SBJ	_	_
7	실내	실내	NNG	NNG	_	8	NP	_	_
8	장식용	장식용	NNG	NNG	_	9	NP	_	_
9	직물	직물	NNG	NNG	_	10	NP	_	_
10	디자이너로	디자이너	NNG	NNG+JKB	JKB	11	NP-AJT	_	_
11	나섰다.	나서	VV	VV+EP+EF+SF	EPIEFISF	0	ROOT	_	



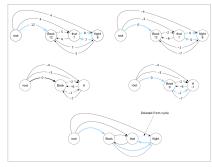


figures from Park (2017c)

전이 기반

그래프 기반

Step	Stack	Word List	Action	Relation Added
0	[root]	[book, the, flight, through, houston]	RIGHTARC	$(root \rightarrow book)$
1	[root, book]	[the, flight, through, houston]	SHIFT	
2	[root, book, the]	[flight, through, houston]	LEFTARC	(the ← flight)
3	[root, book]	[flight, through, houston]	RIGHTARC	$(book \rightarrow flight)$
4	[root, book, flight]	[through, houston]	SHIFT	
5	[root, book, flight, through]	[houston]	LEFTARC	(through ← houston)
6	[root, book, flight]	[houston]	RIGHTARC	(flight → houston)
7	[root, book, flight, houston]	0	REDUCE	
8	[root, book, flight]		REDUCE	
9	[root, book]	П	REDUCE	
10	[root]	0	Done	
	Figure 13.10 A	processing trace of Book the flight t	hrough Houst	on using the arc-eager



figures from Jurafsky and Martin (2018)

 Advanced Computational linguistics (CSE/LIN667, Fall 2018) on dependency parsing and FrameNet (University at Buffalo)⁷

⁷https://sites.google.com/view/aclfall2018/

의존구조 분석 자원

- MaltParser (Nivre et al., 2006)⁸를 사용한 한국어 의존구조 분석 (Park, 2017b)⁹
 - 한국어 의존구조 분석 연구 (Park et al., 2013, 2016; Park, 2017c)

⁸http://www.maltparser.org

⁹http://doi.org/10.5281/zenodo.891274

의존구조 분석 실습

- java MakeMaltTestIn sejong-output.txt > malt-input.txt
- java -jar maltparser-1.9.2.jar -c sejong-malt -i
 malt-input.txt -o malt-output.txt -m parse



- Choi, D., Park, J., and Choi, K.-S. (2012). Korean Treebank Transformation for Parser Training. In Proceedings of the ACL 2012 Joint Workshop on Statistical Parsing and Semantic Processing of Morphologically Rich Languages, pages 78–88, Jeju, Republic of Korea. Association for Computational Linguistics.
- Jurafsky, D. and Martin, J. H. (2018). Speech and Language Processing (3rd ed. draft). http://www.web.stanford.edu/~jurafsky/slp3/, third edition.
- Nivre, J., Hall, J., and Nilsson, J. (2006). MaltParser: A Data-Driven Parser-Generator for Dependency Parsing. In Proceedings of the Fifth International Conference on Language Resources and Evaluation (LREC'06).
- Park, J. (2017a). Berkeley parser model for Korean: Sejong treebank. 10.5281/zenodo.891267.
- Park, J. (2017b). MaltParser model for Korean: Sejong treebank. 10.5281/zenodo.891273.
- Park, J. (2017c). Segmentation Granularity in Dependency Representations for Korean. In Proceedings of the Fourth International Conference on Dependency Linguistics (Depling 2017), pages 187–196, Pisa, Italy. Association for Computational Linguistics.
- Park, J. (2018). Word Granularity in Korean. ACM Transactions on Asian and Low-Resource Language Information Processing (TALLIP), (Under review).
- Park, J., Hong, J.-P., and Cha, J.-W. (2016). Korean Language Resources for Everyone. In Proceedings of the 30th Pacific Asia Conference on Language, Information and Computation: Oral Papers (PACLIC 30), pages 49–58, Seoul, Korea. Pacific Asia Conference on Language, Information and Computation.
- Park, J., Kawahara, D., Kurohashi, S., and Choi, K.-S. (2013). Towards Fully Lexicalized Dependency Parsing for

- Korean. In *Proceedings of The 13th International Conference on Parsing Technologies (IWPT 2013)*, Nara, Japan. International Conference on Parsing Technologies (IWPT 2013).
- Park, J. and Kim, M. (2019). A Note on Constituent Parsing for Korean. Natural Language Engineering, Cambridge University Press (Under review).
- Park, J. and Tyers, F. (2019). A New Annotation Scheme for the Sejong Part-of-speech Tagged Corpus. In Proceedings of the 13th Linguistic Annotation Workshop (The LAW XIII).
- Petrov, S., Barrett, L., Thibaux, R., and Klein, D. (2006). Learning Accurate, Compact, and Interpretable Tree Annotation. In Proceedings of the 21st International Conference on Computational Linguistics and 44th Annual Meeting of the Association for Computational Linguistics, pages 433–440, Sydney, Australia. Association for Computational Linguistics.
- Straka, M. and Straková, J. (2017). Tokenizing, POS Tagging, Lemmatizing and Parsing UD 2.0 with UDPipe. In Proceedings of the CoNLL 2017 Shared Task: Multilingual Parsing from Raw Text to Universal Dependencies, pages 88–99, Vancouver, Canada. Association for Computational Linguistics.